Алгоритмы и структуры данных. Семинар XX. Строки. Часть первая. Григорьев Дмитрий БПМИ-163

Задача 1.

Для начала проверим, что $|s_1| = |s_2|$, если это неверно, то строка s_1 не может являться циклическим сдвигом строки s_2 .

Склеим две строки s_2 , то есть получим две подряд идущих строки s_2 , $s_3 = s_2 + s_2$. Далее проверим с помощью функции isSubstring является ли строка s_1 подстрокой новой строки s_3 . Таким образом, функцию isSubstring вызовем один раз.

Почему это будет работать?

Очевидно что в строке s_2 разных циклических двигов – $|s_2|$, так как они будут повторятся потом. Циклический сдвиг – это склееные две строки:

- 1) суффикс s_2 длины $m, m <= |s_2|$
- 2) префикс s_2 длины $|s_2| m$

А новая строка s_3 как раз содержит все возможные варианты склеенных суффиксов и префиксов строки s_2 .

Задача 2.

Нам нужно построить префикс-функцию, имея посчитанную Z-функцию, не восстанавливая строки.

Если внимательно посмотреть на Z-функцию и на ее определение и так же на префикс-функцию, то заметим, что:

- 1) в Z-функции каждый элемент Z[i] равен длиннейшему префиксу подстроки, начинающейся с позиции і в строке S, который одновременно является и префиксом всей строки S.
- 2) в префикс-функции P[i] длина наибольшего префикса строки $S[0\dots i]$, (исключая вырожденный случай, где префикс совпадает с этой строкой), который одновременно является её суффиксом.

Поэтому если Z[i]>0, то для всех элементов с индексом i+j, где $0\leq j< Z[i]$, значение P[i+j] будет не меньше, чем длина подстроки с i по i+j, что равно j+1. Но если мы до этого обновили значение P[i+j], то это было раньше чем в позиции i, поэтому нам не нужно обновлять значение с P[i] по P[i+j], так как мы только сможем уменьшить его, так как если i'< i, то j'>j, так как i'+j'=i+j, следовательно каждый элемент P[i] мы обновм только один раз, поэтому этот алгоритм будет линейным.

```
Пример кода:
```

```
for (int i = 0; i < n; ++i) {
    P[i] = 0;
}
for(int i = 1; i < n; ++i) {
    if (Z[i] > 0) {
        for(int j = Z[i] - 1; j >= 0 && (P[i + j]) == 0; --j) {
            P[i + j] = j + 1;
        }
    }
}
```

Задача 3.

Заметим, что ответом будет длина наименьшей строки, порождающей исходную строку, то есть длина такой строки, при склеивании которой несколько раз получается исходная.

Найти длину такой строки можно с помощью префикс-функции.

Посчитаем префикс-функцию для строки |s|.

Далее если |s| делится на |s|-p[|s|-1], то ответом и будет |s|-p[|s|-1], иначе ответ |s|.

Если |s| делится на |s|-p[|s|-1], то строку s можно представить в виде суммы строк длины |s|-p[|s|-1], причём, по определению префикс-функции, префикс длины n-|s|-p[|s|-1] будет совпадать с её суффиксом. Но тогда последний блок должен будет совпадать с предпоследним, предпоследний - с предпредпоследним, и т.д. В итоге получится, что все блоки блоки совпадают, и такое |s|-p[|s|-1] действительно подходит под ответ.

Задача 4.

Разобьем стороку p на подстроки по символу *. Тогда p можно разбить на некоторое множество подстрок. Если все эти подстроки входят в строку s и позиции их вхождения возрастают, то можно сделать так, чтобы строка p стала подстрокой s. Для того, чтобы проверить, что все подстроки p входили в s, с возрастающим вхождением, посчитаем префикс-функцию для строки s, далее с помощью алгоритма Кнута-Морриса-Пратта будем считать, является ли очередная подстрока из p подстрокой s. Но при переходе к новой подстроке p мы будем не заново пересчитывать префикс-функцию для строки s, а пересчитывать с вхождения предыдущей подстроки p. Если же вхождения какой либо подстроки p не существует, то p не может быть подстрокой s. Таким образом мы вычислим префикс функцию для всех подстрок p и префикс функцию для s. Используемое время — O(|t| + |s|).

Задача 7.

a)

Воспользуемся алгоритмом Ахо-Карасика

Обычный Ахо-Карасик будет иметь квадратичную ассимптотику, поэтому будем хранить "хорошую суффиксную ссылку" – это ближайший суффикс, имеющийся в боре, для которого flag=true. Число "скачков" при использование таких ссылок уменьшится и станет пропорционально количеству искомых вхождений, оканчивающихся в этой позиции.

Вычислять будем ленивой динамикой. Если для вершины по суффиксной ссылке flag=true, то это и есть искомая вершина, в ином случае рекурсивно запускаемся от этой же вершины.

Задача 9.

а) Воспользуемся алгоритмом Манакера

Введем два массива d_1, d_2 – количество палиндромов соответственно нечётной и чётной длины с центром в позиции і. Для быстрого вычисления будем поддерживать границы (l,r) самого правого из обнаруженных подпалиндрома (т.е. подпалиндрома с наибольшим значением r).

При этом все предыдущие значения в массиве d уже посчитаны. Возможны два случая:

i>r, т.е. текущая позиция не попадает в границы самого правого из найденных палиндромов. Тогда просто запустим наивный алгоритм для позиции i.

 $i\leqslant r$. Тогда попробуем воспользоваться значениями, посчитанным ранее. Отразим нашу текущую позицию внутри палиндрома [l;r]:j=(r-i)+l. Поскольку i и j — симметричные позиции, то если $d_1[j]=k$, мы можем утверждать, что и $d_1[i]=k$. Это объясняется тем, что палиндром симметричен относительно своей центральной позиции. Т.е. если имеем некоторый палиндром длины k с центром в позиции $l\leqslant i\leqslant r$, то в позиции j, симметричной i относительно отрезка [l;r] тоже может находиться палиндром длины k. Это можно лучше понять, посмотрев на рисунок. Снизу фигурными скобками обозначены равные подстроки. Однако стоит не забыть про один граничный случай: что если $i+d_1[j]-1$ выходит за границами это палиндрома? Так как информации о том, что происходит за границами это палинлрома у нас нет (а значит мы не можем утверждать, что симметрия сохраняется), то необходимо ограничить значение $d_1[i]$ следующим образом: $d_1[i]=\min(r-i,d_1[j])$. После этого запустим наивный алгоритм, который будет увеличивать значение $d_1[i]$, пока это возможно. После каждого шага важно не забывать обновлять значения [l;r].

Заметим, что массив d_2 считается аналогичным образом, нужно лишь немного изменить индексы.

Описанный выше алгоритм работает за время O(n).